

Day3 · 18차시

모니터링 & 관찰성

17차시에서 계측을 붙였다 — 이제 그 신호로 서비스를 운영한다.
대시보드로 읽고 · 알림으로 깨우고 · 드리프트를 잡는다.

SECTION 00

오프닝 — 계측 다음에 오는 것

17차시: 신호를 '남겼다' → 18차시: 신호로 '결정한다'

“내 에이전트가 지금 빠른가? 느린가? 실패하나? 똑똑한가? — 숫자로 답할 수 있나?”

— 계측은 17차시에 붙었다. 오늘은 그 숫자로 답하고 행동한다.

계측을 붙였다 → 이제 운영한다

▶ 신호를 '쓴다'

17차시 — 계측을 붙였다

- '@observe()'로 trace 생성
- 'langfuse.openai'로 토큰·비용
- 'score'로 품질 기록
- self-host 띄우기


VS

18차시(오늘) — 신호로 운영한다

- 대시보드로 P95·비용·품질을 읽고
- 알림으로 이상을 먼저 알고
- 상시 Eval·드리프트로 표류를 잡고
- 배포 패턴·비용 티어로 결정한다

이 차시 동안 얻는 것

▶ 17차시에서 불인 신호를 운영으로 바꾸는 네 걸음



SECTION 01

무엇을 관찰하나

신호는 붙였다 — 그 중 무엇을 봐야 하는가

에이전트는 확률적으로 동작한다

▶ 모든 시나리오를 출시 전에 테스트할 수 없다 → 모니터링이 배포 인프라의 신경계

∞

가능한 입력 —
전부 테스트 불가

변동

같은 입력도
매번 다른 출력

연쇄

도구·LLM 호출이
사슬로 엮임

무엇을 숫자로 볼 것인가

▶ 앞 셋은 전통 모니터링 — 품질은 LLM 고유, 우리가 따로 정의해야 한다

지연 Latency

평균이 아니라
P50 / P95 / P99

비용 Cost

토큰 → \$ 환산
모델·기능별로

실패 Failure

에러 + 폴백
+ 작업 포기

품질 Quality

정확·환각·만족
우리가 정의

크래시 없이도 실패한다

▶ 전통 모니터링은 '살아있나'에만 답한다 — 우리는 '의도대로 작동하나'를 물어야 한다

인프라 신호 (전통)

- 지연·에러율·CPU·가동시간
- “살아있나?”에 답
- 200 OK = 정상으로 보임
- 수치는 멀쩡한데 답은 틀릴 수 있음

VS

시맨틱 행동 (LLM 고유)

- 의도 파악·도구 선택·환각·작업 포기
- “의도대로 작동하나?”에 답
- 도구는 성공했는데 답이 틀림
- 유창하지만 환각

실패의 뿌리는 셋 — 처방이 다르다

▶ 같은 '틀린 답'이라도 뿌리에 따라 고치는 곳이 다르다

① 소프트웨어 버그

결정적으로 재현 — 코드 수정으로 해결

② 모델 변동

출력이 흔들림 — 프롬프트·그라운드링 조정으로 해결

③ 아키텍처 한계

설계 자체의 제약 — 재설계가 필요

메트릭을 추상화 계층별로

▶ '다 수집'이 아니라 의미 있는 변화를 잡을 만큼만 — 각 메트릭엔 액션을 연결

④ 사용자 피드백

재질의율·작업 포기율 👍/👎

③ 출력 품질

입·출력 토큰·환각 지표·임베딩 드리프트

② 워크플로우

작업 성공률·토큰 사용·도구 성공/실패·재시도·폴백

① 인프라

CPU·가동시간·요청 지연 P50/95/99

수집이 아니라 행동이다

▶ 메트릭마다 '넘으면 무엇을 한다'를 미리 — 액션 없는 대시보드는 예쁜 벽지

지연 급증

→ 캐싱 · 병렬화 · 모델 티어 점검

비용 급증

→ 싼 모델로 라우팅 · 티어 조정

score 하락

→ 프롬프트 점검 · 회귀 케이스 추가

실패 발생

→ 알림 · 폴백 · 롤백

SECTION 02

신호를 남기고 지킨다 — 로깅·보관·PII

이미 붙인 계측 — 오늘은 이 신호를 '운영'한다

▶ 새로 배우지 않는다. 17차시에서 한 줄씩 붙였다 → 오늘은 그 신호를 쓴다

``@observe()``

함수를 trace로 — 입력·출력·지연 자동

``langfuse.openai``

import 한 줄로 토큰·비용 자동

``score_current_trace``

품질을 숫자로 trace에

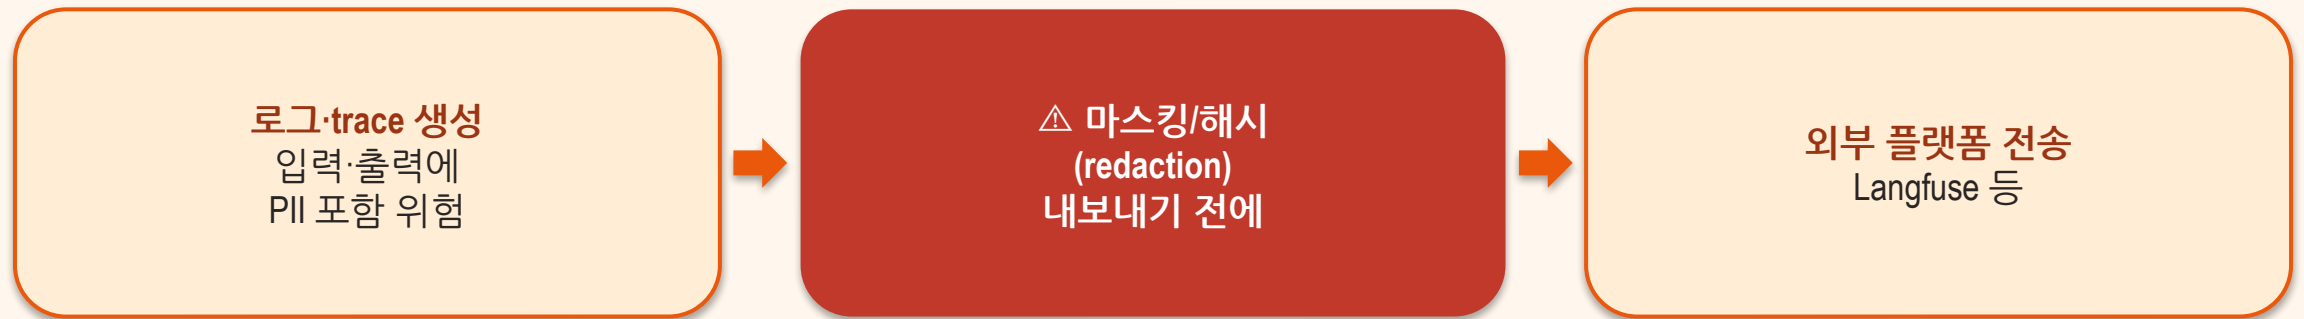
요청마다 무엇을 남기나

▶ 검색·집계 가능한 구조화(JSON) 로그로 — 평문 텍스트가 아니라 필드로

```
log = {  
  "trace_id": "req-8f3a", "ts": "2026-06-28T09:12:03Z",  
  "latency_ms": 1840, "prompt_tokens": 320, "completion_tokens": 110,  
  "ok": True, "score": 0.92, "model": "gpt-4o-mini",  
  "input": "...", "output": "..." # 민감정보는 마스킹/해시  
}
```

내보내기 전에 가린다 (PII)

▶ 무엇을 남기고 무엇을 가릴지 정책으로 — 관찰성과 프라이버시는 같이 간다



SECTION 03

대시보드 & 알림 — 신호로 결정한다

쌓은 trace를 '읽고' '깨우는' 곳 — 여기가 운영의 시작

보는 항목 ↔ 내리는 액션

▶ 대시보드는 보는 곳이 아니라 결정하는 곳

Langfuse가 보여주는 것

- Traces: 요청 드릴다운
- Latency: P50/95/99
- Cost/Tokens: 모델·세션별
- Scores: 품질 추세


VS

거기서 내리는 액션

- 느린 trace → 캐싱·병렬화
- 지연 급증 → 모델 티어 조정
- 비용 급증 → 싼 모델로
- score 하락 → 프롬프트 점검

17에서 쌓은 신호가 여기 모인다

▶ 로컬 Langfuse Home — Traces 44 · Cost \$0.003 · Scores 92 (groundedness·relevance·completeness)



트레이스 목록과 P95 지연

▶ 왼쪽: 요청 하나하나로 파고든다 · 오른쪽: 지연을 평균이 아니라 P95로 본다

The screenshot shows the Langfuse Tracing interface. On the left is a sidebar with navigation links: Home, Dashboards, Observability, Tracing (selected), Sessions, Users, Prompt Management, Prompts, Playground, Evaluation, Scores, Evaluators, Human Annotation, and Datasets. The main area is titled 'Tracing' and contains a table of traces. The table has columns for 'Timestamp', 'Name', 'Input', and 'Output'. The 'Name' column includes a star icon and a timestamp. The 'Input' column shows the user's prompt, and the 'Output' column shows the model's response. The table is filtered by 'Environment' (sdk-experiment, default) and 'Trace Name' (sdk-experiment, default). The 'Trace ID' column is expanded, showing a list of trace IDs. The 'User ID' column is also expanded, showing a list of user IDs. The 'Tags' column is expanded, showing a list of tags. The 'Metadata' column is expanded, showing a list of metadata items. The 'Version' column is expanded, showing a list of versions. The 'Release' column is expanded, showing a list of releases. The 'Bookmarked' column is expanded, showing a list of bookmarked items. The 'Comment Count' column is expanded, showing a list of comment counts. The 'Comment Content' column is expanded, showing a list of comment contents. The 'Level' column is expanded, showing a list of levels. The 'Latency' column is expanded, showing a list of latencies. The 'Input Tokens' column is expanded, showing a list of input tokens. The 'Output Tokens' column is expanded, showing a list of output tokens. The 'Total Tokens' column is expanded, showing a list of total tokens. The 'Input Cost' column is expanded, showing a list of input costs. The table is sorted by 'Timestamp' in descending order. The bottom of the table shows 'Rows per page' (50), 'Page' (1), and 'of 1'.

The screenshot shows the Langfuse Latency Dashboard. The dashboard is titled 'Langfuse Latency Dashboard (Langfuse Maintained)'. It features several charts and metrics. The 'P 95 Latency by Use Case' chart shows latency metrics for different use cases. The 'P 95 Latency by Level (Observations)' chart shows latency metrics for different levels. The 'Max Latency by User Id (Traces)' chart shows the maximum latency for the top 50 users. The 'Avg Time To First Token by Prompt Name (Observations)' chart shows the average time to first token for different prompt names. The 'P 95 Time To First Token by Model' chart shows the P95 time to first token for different models. The 'P 95 Latency by Model' chart shows the P95 latency for different models. The 'Avg Output Tokens Per Second by Model' chart shows the average output tokens per second for different models. The dashboard also includes a sidebar with navigation links: Home, Dashboards (selected), Observability, Tracing, Sessions, Users, Prompt Management, Prompts, Playground, Evaluation, Scores, Evaluators, Human Annotation, and Datasets. The bottom of the dashboard shows 'Rows per page' (50), 'Page' (1), and 'of 1'.

이상을 사람보다 먼저 — 알림 규칙

▶ 알림이 너무 잦으면 무시하게 된다 — 의미 있는 이상만 깨운다

1

임계값을 정한다

지연 > 한계 / score < 하한 / 실패 발생

2

규칙을 건다

대시보드 또는 코드에서 조건 설정

3

채널로 보낸다

Slack·이메일 등으로 알림 전송

4

과잉 반응 금지

확률적 변동 한 번에 깨우지 않게 — 추세·재현으로 판단

Automations — 트리거 정해두고 알림을 건다

▶ 조건(트리거)이 맞으면 자동으로 Webhook·Slack·GitHub로 — 서명 헤더로 위·변조까지 검증

langfuse v3.210.0 OSS

vibe-org / vibe-project / Prompts

Go to... x K

Home

Dashboards

Observability

Tracing

Sessions

Users

Prompt Management

Prompts

Playground

Evaluation

Scores

Evaluators

Human Annotation

Datasets

+ Create Automation

Automations

No automations configured. Create your first automation to streamline workflows.

The event that triggers this automation.

Event Action

Actions created updated deleted

The actions on the event source that trigger this automation.

Filter

+ Add filter

Add conditions to narrow down when this trigger fires.

Action

Configure what happens when the trigger fires.

Action Type

Webhook

The type of action to perform when the trigger fires.

Webhook URL *

https://hooks.slack.com/services/T0ABCDEF/B0GHIJKL/matjipQualityAlertToken

The HTTP URL to call when the trigger fires. We will send a POST request to this URL. Only HTTPS URLs are allowed for security.

API Version

v1

The API version to use for the webhook payload format when prompt events are triggered.

Headers

Default headers (automatically added by Langfuse):

content-type	application/json
user-agent	Langfuse/1.0
x-langfuse-signature	t=<timestamp>;v1=<signature>

Optional custom headers to include in the webhook request:

+ Add Custom Header

Star Langfuse x

See the latest releases and help grow the community on GitHub


저장하면 '활성' 알람이 상시 감시한다

▶ 좌: 등록된 알람(prompt → Webhook · Active) · 우: 실행 이력으로 언제·왜 올랐는지 추적 — 단, OSS 트리거 소스는 Prompt 이벤트

The screenshot displays the Langfuse web interface. The top navigation bar includes the Langfuse logo, version 'v3.210.0 OSS', and breadcrumb navigation: 'vibe-org' / 'vibe-project' / 'Prompts'. A left sidebar lists various features: 'Go to...', 'Home', 'Dashboards', 'Observability', 'Tracing', 'Sessions', 'Users', 'Prompt Management', 'Prompts', 'Playground', 'Evaluation', 'Scores', 'Evaluators', and 'Human Annotation'. The main content area is titled 'Automations' and features a '+ Create Automation' button. Below this, a card for '프로덕션 프롬프트 변경...' (Production Prompt Change) is shown as 'Active' with a 'prompt → Webhook' trigger. To the right, the '프로덕션 프롬프트 변경 알람 (production 라벨)' (Production Prompt Change Alert (production label)) is also 'Active', with 'Edit' and 'Delete' buttons. The 'Execution History' tab is selected, showing a table with columns: Status, Started, Duration, Input, Output, and Error. The table is currently empty, displaying 'No results.' at the bottom. Pagination controls at the bottom right indicate 'Rows per page: 50', 'Page: 1 of 0', and navigation arrows.

진짜 실패 vs 예상된 변동

▶ 확률적 시스템 — 한 번 다르다고 장애가 아니다. 재현성·분산으로 구분 후 알림



SECTION 04

상시 Eval · 드리프트 · 배포 · 비용

Eval을 라이브로 계속 (합성 모니터링)

▶ Eval은 출시 전 1회가 아니라 라이브로 계속 돈다

1

카나리아 질문 발사

정답을 아는 요청을 주기적으로 자동 전송

2

응답 채점(score)

출력을 자동 검증

3

임계 미달 시 알림

기준 밑으로 떨어지면 즉시 플래그

4

실패를 회귀 케이스로

실패 = 새 테스트 케이스로 저장 (shift left)

서서히 변하는 것을 숫자로 잡는다

▶ 급격한 장애보다 무서운 건 조용한 표류 — 분포 비교 3가지 도구

KS 검정

연속 지표(질의 길이·지연)의 분포 비교 — 통계량 > 0.1 이면 주의

KL 발산

토큰·임베딩 패턴의 개념 드리프트 — > 0.5 이면 주의

PSI

입력 분포의 시점 간 이동 — $0.1 \sim 0.25$ 경미 / > 0.25 심각

약어가 뜻하는 것과 읽는 법

▶ 이름(원어)·무엇을 재나·어떻게 읽나 — 수식은 몰라도, 무엇을·언제 쓰는지 알고 가자

1

KS 검정 — Kolmogorov-Smirnov (콜모고로프·스미르노프)

두 분포의 누적분포함수(CDF) 최대 간격을 D 통계량으로. 라벨 없이 쓰는 연속값(질의 길이·지연·score)용. D 0=동일 · >0.1 주의 · >0.2 드리프트 의심

2

KL 발산 — Kullback-Leibler divergence (쿨백·라이블러)

기준 분포 P 대비 현재 Q의 정보량 차이(비대칭 — $P||Q \neq Q||P$). 토큰·임베딩·주제 분포의 '개념 드리프트'용. 0=동일 · >0.5면 주의(단위 nat)

3

PSI — Population Stability Index (모집단 안정성 지수)

구간별 (현재%-기준%) $\times \ln$ (현재%/기준%)의 합. 신용평가에서 유래, 입력 분포 이동용. <0.1 안정 · 0.1~0.25 경미 · >0.25 심각

모니터링을 등에 업은 배포 3종

▶ 새 버전을 '한 방'이 아니라 관찰하면서 내보낸다

새도 모드

신버전을 병렬 실행
사용자 노출 없이
로그만 비교

카나리 배포


실트래픽 1~5%만
신버전으로 —
버전 태그로 지표 비교

회귀 코퍼스

프로덕션 실패를
테스트 스위트로 자동 수출
— 살아있는 CI 코퍼스

이상을 감지하면 스스로 물러선다 (Self-healing)

▶ 완벽한 답 대신 — 더 단순한 계획, 선택 단계 생략, 사람에게 위임



☞ 모니터링이 장애 탐지를 넘어 — 에이전트의 반사신경이 된다

토큰 → 비용(\$), 그리고 모델 티어

▶ score 대비 비용으로 '품질을 유지하는 가장 싼 구성'을 데이터로 찾는다

싼 모델 (gpt-4o-mini)

- 단순·대량·실시간
- 분류·요약·추출
- 비용 절감

VS

비싼 모델 (gpt-4o)

- 복잡·고품질
- 다단계 추론·중요 결정
- 정확도 우선

SECTION 05

정리

오늘 3줄

- 17차시에서 붙인 신호(지연·비용·실패·품질)를 대시보드로 읽고 알림으로 깨운다
- 상시 Eval(카나리아)·드리프트(KS·KL·PSI)로 조용한 표류를 잡는다
- 목적은 수집이 아니라 **행동** — 배포 패턴·비용 티어·폴백·롤백으로 결정한다

관찰할 수 없는 것은 운영할 수 없다.

— 대시보드는 보는 곳이 아니라 결정하는 곳