

Day3 · 20차시

평가 (Langfuse Evaluation)

바꾼 게 정말 더 나은가? — 느낌이 아니라 숫자로.
데이터셋 × 평가자 → 점수 — 두 버전을 비교해 배포를 결정한다.

SECTION 00

오프닝 — 정답이 하나가 아닌 것을 쟀다

“생성 출력은 정답이 하나가 아니다 — 그럼 품질을 어떻게 숫자로 재나?”

— 무한 확률 공간의 출력을 정량·정성으로 측정하는 것이 LLM 평가의 도전

버전을 만들었으면, 이제 잔다

▶ 프롬프트 관리 + 평가 = 안전한 개선 루프 — 측정 없이는 개선도 없다

19차시 — 프롬프트 관리

- 프롬프트를 버전 자산으로
- v2를 만들었다
- 질문: “어떻게 안전하게 바꾸나?”

VS

20차시 — 평가

- v2가 정말 더 나은지 측정
- 숫자로 배포를 결정
- 질문: “느낌이 아니라 증거는?”

이 차시 동안 얻는 것



SECTION 01

왜·무엇을 평가하나

결정적 코드 vs 생성 출력

▶ LLM은 비결정적 — 전통 단위테스트(정확 일치)로 못 잡는다

결정적 코드

- 정답 1개
- 정확 일치 테스트
- 통과/실패 명확

VS

생성 출력

- 허용 답 다수
- 품질은 '정도' 문제
- 유창한 환각 위험

무엇을 평가하나 — 6가지 대표 기준

▶ 기준은 도메인마다 다르다 — 우리 MVP가 '지켜야 할 것'을 먼저 정한다

정확성

사실과 일치하는가

관련성

질문 의도에 맞는가

충실성 (그라운드링)

주어진 근거에만 기대는가 — 환각 감지

형식 준수

JSON·길이·톤을 지켰는가

안전성

유해·편향 출력은 없는가

간결성

군더더기 없이 답했는가

평가의 3축 — 무엇을 어떻게 볼 것인가

▶ 한 평가가 세 축 위 어딘가에 놓인다 — 축을 알면 빠진 평가가 보인다

수동 ↔ 자동

사람 판단 vs 도구 채점 — 신뢰 vs 규모

결과 ↔ 궤적

최종 출력만 vs 거기까지의 경로(도구 호출·추론)까지

능력 ↔ 안전

잘하는가 vs 공격에도 안 무너지는가 (21차시)

오프라인 vs 온라인 평가

▶ 18차시 관찰성의 score가 온라인 평가의 토대

오프라인 평가

- 배포 전
- 고정 데이터셋
- 회귀 검증

VS

온라인 평가

- 배포 후
- 실트래픽
- 상시 채점 (카나리아)

평가의 3요소

▶ 이 셋을 묶어 한 번 돌린 것이 실험(Experiment) — 오늘 모든 도구가 이 구조 위에

데이터셋

대표 입력 + 기대값

평가자

채점 함수 — 규칙·LLM 심판·사람

점수 (Score)

항목별 결과 → 런끼리 비교

SECTION 02

평가 방법 — 규칙 · 심판 · 사람

규칙 기반 평가

▶ '지켜야 할 최소선'에 적합 — 그러나 '얼마나 좋은가'는 못 잰다

무엇

형식·키워드·길이·정규식 등 결정적 검사

장점


싸고 빠르고 재현 가능 — 언제 돌려도 같은 결과

한계

“얼마나 좋은 추천인가” 같은 주관적 품질은 못 잰다 → LLM 심판

LLM-as-a-judge — 출력을 다른 LLM이 채점

▶ 사람 평가에 근접 + 수천 건 자동 — 단, 심판도 틀린다



LLM 심판의 3대 편향과 완화책

▶ 심판을 검증하는 것도 평가의 일부

자신감 편향

유창하게 들리는 오답을 선호 → 이유(reasoning)를 먼저 쓰게 강제

위치 편향

A/B 순서에 따라 판정이 바뀜 → 순서를 랜덤화해 두 번 채점

자기 선호

같은 모델 계열의 출력에 후함 → 다른 모델 심판·양상블

사람 평가 — 직접 채점 vs 선호 비교

▶ 절대 점수는 흔들린다 — '어느 쪽이 나은가'가 더 안정적

직접 채점 (absolute)

- “이 답은 4점” — 절대 평가
- 사람마다 기준이 달라 노이즈 큼
- 루브릭이 있어야 안정


VS

선호 비교 (preference)

- “A와 B 중 어느 쪽?” — 상대 평가
- 더 일관적 — 승률로 집계
- Elo 레이팅(Chatbot Arena)로 확장

칼때기 — 규칙 · 심판 · 사람

▶ 규칙+심판으로 1차 필터, 사람은 샘플만



공개 벤치마크, 참고만 하라

▶ MMLU 고득점 ≠ 우리 앱에 강함 — 결론: 내 작업의 커스텀 평가셋이 답

무엇이 있나

MMLU(지식)·SWE-Bench(코딩)·BFCL(도구 호출)·GAIA(에이전트) 등

함정 ① 오염

벤치마크 문제가 학습 데이터에 이미 들어감(contamination) — 실력 아닌 암기

함정 ② 포화

85%+ 구간에선 변별력 상실(saturation)

함정 ③ 불일치

벤치마크 점수와 우리 도메인 성능은 다른 문제

SECTION 03

Langfuse로 평가하기

관찰성(18)·프롬프트 관리(19)와 같은 플랫폼에서 평가까지

Langfuse 평가 데이터 모델

▶ 평가의 3요소가 그대로 Langfuse 객체로 매핑된다

Dataset

평가 항목의 모음 — 버전 관리되는 평가셋

Dataset Item

입력 + 기대 출력 한 쌍

Run / Experiment

데이터셋을 한 번 실행한 결과

Score

각 항목의 점수 — 런끼리 비교의 재료

Datasets — 평가셋 카탈로그

▶ 프로젝트에 등록된 평가셋 목록 — 각 셋의 항목 수·러 수가 하능에

langfuse v3.210.0 OSS

Vibe Coding Workshop / test-blog-matjip

Go to...

Home

Dashboards

Observability

Tracing

Sessions

Users

Prompt Management

Prompts

Playground

Evaluation

Scores

Evaluators

Human Annotation

Datasets

Star Langfuse

Settings

Book a call

Support

위강 워크샵 강사 workshop@exam...

Datasets

My Views 0

Search (Name)

Columns 11/11

☐	Name	Description	Items	Experi...	Created	Last Run	Input Sch...	Expected ...	Metadata
☐	matjip-eval	맛집 추천 품질 회귀 평가셋	5	2	2026-07-10 12:41:16	2026-07-10 12:42:05			

Rows per page 50 Page 1 of 1

create_dataset · create_dataset_item

▶ 어려운·실패했던 케이스를 모아라 — 운영 버그가 곧 새 평가 항목

```
langfuse.create_dataset(name="matjip-eval")
langfuse.create_dataset_item(
    dataset_name="matjip-eval",
    input="강남 2만원 이하 매운 점심",
    expected_output="강남")
```

등록된 평가셋

▶ 입력(query)과 기대 출력(expected)이 싹으로 — 어려웠던·실패했던 케이스를 모은다

langfuse v3.210.0 OSS

Vibe Coding Workshop / test-blog-matjip / Datasets

Go to...

Home

Dashboards

Observability

Tracing

Sessions

Users

Prompt Management

Prompts

Playground

Evaluation

Scores

Evaluators

Human Annotation

Datasets

Star Langfuse

See the latest releases and help grow the community on GitHub

Langfuse 31k

Settings

Book a call

Support

워크샵 강사 workshop@exam...

Dataset matjip-eval

Items Experiments

Search...

IDs

Filters

Columns 8/8

Item id	Source	Status	Created At	Input	Expected Output	Metadata	Actions
6c154f61-e2a...		Active	2026-07-10 12:41:16	1 Items query: "회식 고깃집"	"단체 가능 고깃집 추천, 출처 표기"		
6a071db6-84...		Active	2026-07-10 12:41:16	1 Items query: "비 오는 날 전집"	"전 잘하는 집 추천, 출처 표기"		
52aea8ab-a4...		Active	2026-07-10 12:41:16	1 Items query: "연남동 감성 카페"	"연남동 카페 3곳 추천, 출처 표기"		
3ef79f87-438...		Active	2026-07-10 12:41:16	1 Items query: "혼밥 국밥집"	"1인 좌석 있는 국밥집, 출처 표기"		
49fdb06e-b61...		Active	2026-07-10 12:41:16	1 Items query: "성수동 파스타 데이트 코스"	"성수동 파스타집 3곳, 각 추천에 출처 표기"		

Rows per page 50

Page 1 of 1

run_experiment(task, evaluators)

▶ 트레이스가 아이템에 자동 링크 — 낮은 점수 항목은 바로 원인 추적

```
ds = langfuse.get_dataset("matjip-eval")
def task(*, item, **kw): return app(item.input)
ds.run_experiment(name="run-v1", task=task,
                  evaluators=[rule_evaluator, judge_evaluator])
langfuse.flush()    # 잊으면 전송 안 됨
```


평가자 시그니처 & Score 타입

▶ Evaluation 객체를 반환

```
def rule_evaluator(*, input, output, expected_output, **kw):  
    ok = expected_output in output  
    return Evaluation(name="contains", value=1.0 if ok else 0.0,  
                      comment="기대 키워드 포함 여부")  
  
# 점수 타입: NUMERIC · CATEGORICAL · BOOLEAN  
# 항목별 = evaluators / 런 전체 집계 = run_evaluators
```

Experiments 뷰 — 숫자로 승부를 가린다

▶ '느낌상 v2가 나은 듯'이 아니라 '0.88 대 0.72로 v2 승'

run-v1

- 평균 0.72
- 기준선 (baseline)


VS

run-v2 ▲

- 평균 0.88
- **production** 승격 (19차시 라벨 이동)

두 런을 나란히 — 숫자로 승부

▶ v2-production(completeness Ø0.44)이 v1-baseline(Ø0.25)을 이겼다 — 같은 5개 항목



코드 Evaluator vs 서버 Evaluator

▶ 같은 채점을 코드로 넘기거나, 서버에 등록해 상시 채점

① 코드 Evaluator

- `run_experiment(evaluators=[...])`
- 그때그때 채점
- 빠른 실험·CI


VS

② 서버 Evaluator

- Langfuse에 등록
- 상시·자동 채점
- 팀 공유·재사용 — LLM Connection 필요

서버 Evaluator 등록 흐름

▶ LLM Connection이 먼저 — 그다음 Evaluator, 마지막 Rule



서버 Evaluator = LLM Connection + 심판 규칙

▶ 왼쪽: openai 연결 등록(키는 암호화 저장) · 오른쪽: Hallucination 심판이 실제 생성 트레이스를 상시 채점

The screenshot shows the 'Project Settings' page in the Langfuse interface. The 'LLM Connections' section is active, displaying a table with one connection for 'openai'. The table has columns for Provider, Adapter, Base URL, and API Key. Below the table is a '+ Add LLM Connection' button. The left sidebar shows the navigation menu with 'Evaluators' highlighted.

Provider	Adapter	Base URL	API Key
openai	openai	default	...X-CA

+ Add LLM Connection

The screenshot shows the 'Set up evaluator' page in the Langfuse interface. The 'Generated Score Name' is 'Hallucination'. The 'Run on' section has 'Observations' selected. The 'Run on live incoming observations' toggle is turned on. The 'Filter' section shows 'Where' set to 'Type' and 'any of', and 'And' set to 'Environment' and 'none...'. Below the filters is a table showing sample data over the last 24 hours that match the filters.

Start Time	Type	Name	Input	Output	Level	Latency	To
2026-07-10 12:41:15	답변 생성	"늦게까지 하는 해장국집"	"늦게까지 하는 해장국집"	"늦게까지 하는 해장국집" 요청에 맞춰 3곳 추천드려요. 1) 청...	DEFAULT	1.62s	\$0.
2026-07-10 12:41:13	답변 생성	"매운 음식 잘하는 곳 추천해줘"	"매운 음식 잘하는 곳 추천해줘"	"매운 음식 잘하는 곳 추천해줘" 요청에 맞춰 3곳 추천드려요. 1...	DEFAULT	0.69s	\$0.
2026-07-10 12:41:12	답변 생성	"아이랑 갈 만한 브런치 카페"	"아이랑 갈 만한 브런치 카페"	"아이랑 갈 만한 브런치 카페" 요청에 맞춰 3곳 추천드려요. 1...	DEFAULT	1.53s	\$0.
2026-07-10 12:41:10	답변 생성	"회식 장소로 좋은 고깃집 있을까?"	"회식 장소로 좋은 고깃집 있을까?"	"회식 장소로 좋은 고깃집 있을까?" 요청에 맞춰 3곳 추천드...	DEFAULT	0.79s	\$0.
2026-07-10 12:41:09	답변 생성	"비 오는 날 가기 좋은 전집 추천"	"비 오는 날 가기 좋은 전집 추천"	"비 오는 날 가기 좋은 전집 추천" 요청에 맞춰 3곳 추천드려...	DEFAULT	0.90s	\$0.
2026-07-10 12:41:07	답변 생성	"연날들 감성 카페 알려줘"	"연날들 감성 카페 알려줘"	"연날들 감성 카페 알려줘" 요청에 맞춰 3곳 추천드려요. 1) 소...	DEFAULT	1.54s	\$0.
2026-07-10 12:41:06	답변 생성	"출발하기 위한 국밥집 어디 있어?"	"출발하기 위한 국밥집 어디 있어?"	"출발하기 위한 국밥집 어디 있어?" 요청에 맞춰 3곳 추천드...	DEFAULT	1.08s	\$0.
2026-07-10 12:41:04	답변 생성	"상수동에서 데이트하기 좋은 파스타집 추천해줘"	"상수동에서 데이트하기 좋은 파스타집 추천해줘"	"상수동에서 데이트하기 좋은 파스타집 추천해줘" 요청에 맞...	DEFAULT	1.50s	\$0.
2026-07-10 12:41:03	답변 생성	"늦게까지 하는 해장국집"	"늦게까지 하는 해장국집"	"늦게까지 하는 해장국집" 요청에 맞춰 3곳 추천드려요. 1) 소...	DEFAULT	0.21s	\$0.

Sampling: 100.00 %

서버 Evaluator — 핵심 API 3종

▶ 등록 후엔 로컬 evaluators 없이 run_experiment만 — 서버가 비동기 채점

```
# 1) LLM Connection    PUT /api/public/llm-connections
{"provider":"openai", "adapter":"openai", "secretKey": KEY}
# 2) Evaluator          POST /api/public/unstable/evaluators
{"name":"...", "prompt":"...{{input}} {{output}}...",
 "outputDefinition":{"dataType":"NUMERIC", ...}}
# 3) Rule               POST /api/public/unstable/evaluation-rules
{"evaluator":{...}, "target":"experiment", "mapping":[...]}
```

사용자·세션 단위 집계 (user / session)

▶ '이 사용자에게 유독 나빴나' '이 대화 전체가 이상했나'에 답한다

user_id

트레이스에 사용자를 태깅 → 사용자별 품질 집계

session_id

여러 트레이스를 한 대화로 묶음 → 세션 점수

어떻게

propagate_attributes로 전파 — 18차시 관찰성과 같은 기능

Human Annotation (HITL)

▶ 자동 평가로 1차, 사람 주석으로 최종 — 같은 Scores 뷰에 나란히

자동 평가

- 규칙 기반 + LLM 심판
- 대량·빠름·저렴


VS

사람 주석 (HITL)

- 👍/👎 · 등급 — 가장 신뢰
- 느리고 비쌈 — 샘플만
- 심판이 사람과 일치하는지 검증까지

Annotation Queue — 분배·라벨링

▶ 팀 단위 사람 평가 파이프라인 — 검수자 userId는 프로젝트 멤버여야




SECTION 04

상시 평가·회귀 + 프롬프트 관리 연결


프로덕션 카나리아 (상시 Eval)

▶ 실패는 곧 새 평가 케이스 (shift left) — 사용자보다 먼저 회귀 발견



프롬프트 관리 ↔ 평가 = 한 루프

▶ 19·20차시 = 하나의 안전한 개선 사이클



🔄 회귀가 보이면 → 롤백 / 개선 → 다시 평가

SECTION 05

마무리

오늘 3줄

- 평가 = 데이터셋 × 평가자 → 점수 — 규칙(최소선) + LLM 심판(주관 품질) + 사람(최종)
- 심판도 틀린다 — 편향 3종(자신감·위치·자기 선호)을 앙상블·랜덤화·이유 강제로 완화
- Langfuse `create_dataset` → `run_experiment` → **Scores**로 버전을 숫자로 비교해 배포 결정

측정이 있어야 개선이 있다.

— 느낌이 아니라 숫자로 — 벤치마크 말고 내 작업의 평가셋으로